Динамика связывания Foxd3 в ходе развития нервного гребня *Danio rerio*

Анализ bioChIP-seq на четырёх стадиях: 75% epiboly → 1–2 ss → 5–6 ss → 14 ss

Данные Lukoseviciute et al., 2018, *Dev Cell* (GEO GSE106676), геном GRCz11

1 Цель работы

Проследить, как меняется геномный ландшафт связывания транскрипционного фактора Foxd3 от гаструляции до миграции нервного гребня, и отделить различия, которые можно считать биологическими, от различий, которые могут быть вызваны качеством отдельных библиотек ChIP-seq.

Для этого стадии 75% epiboly (75ep) и 1–2 ss были самостоятельно обработаны тем же конвейером, что и стадия 14 ss на семинаре; стадия 14 ss была также пересчитана заново. Для 5–6 ss использованы готовые файлы преподавателя. Затем четыре стадии сравнивались по числу пиков, FRiP, силе обогащения, попарному перекрытию, индексу Жаккара и стадийно-специфичным пикам; характерные локусы проверены в IGV.

2 Использованные данные

Стадия	Этап развития	ChIP	Input	Источник результата
75ep	гаструляция	`foxd3_75ep_chip.nuclear.bam`	`foxd3_75ep_input.nuclear.bam`	собственный анализ
1–2ss	индукция нервного гребня	`foxd3_1-2ss_chip.nuclear.bam`	`foxd3_1-2ss_input.nuclear.bam`	собственный анализ
5–6ss	спецификация нервного гребня	готовые BigWig, narrowPeak, matrix, frip.tsv		`teacher_example/5-6ss`
14ss	миграция нервного гребня	`foxd3_14ss_chip.nuclear.bam`	`foxd3_14ss_input.nuclear.bam`	собственный анализ (данные семинара)

Табл. 1. Все BAM — paired-end выравнивания на GRCz11, отфильтрованные от митохондриальных ридов. Хромосомы названы по RefSeq: `NC_007112.7` = chr1 … `NC_007136.7` = chr25; `NW_…` — неразмещённые скаффолды.

Дизайн эксперимента. Foxd3 несёт AviTag и биотинилируется *in vivo* биотин-лигазой BirA. После сшивки и фрагментации хроматина Foxd3 со связанной ДНК вытягивают стрептавидином (bioChIP) и секвенируют. Контроль **Input** — хроматин до обогащения: он отражает неравномерность фрагментации, картируемость, GC-смещение и копийность. Отдельный контроль **BirA-only** (эмбрионы без Foxd3-Avi) показывает неспецифический захват стрептавидином; в нашем peak calling он не использовался, пики вызывались относительно Input. ChIP делается из **целых эмбрионов**, поэтому сигнал от Foxd3^{+} клеток разбавлен всеми остальными клетками.

3 Форматы файлов

Формат	Что хранит (биологический / вычислительный объект)	Text / Binary	Для чего использовали
FASTA (.fa)	Последовательность референсного генома: для каждой хромосомы заголовок `>имя` и строки нуклеотидов A/C/G/T/N. Сопровождается индексом .fai (длины хромосом и смещения в файле)	Text	Референс GRCz11; система координат всех остальных файлов
GTF	Аннотация генов: 9 колонок — хромосома, источник, тип объекта (gene / transcript / exon / CDS), start, end, score, strand, frame и атрибуты (`gene_id` , `transcript_id` , имя гена). Координаты 1-based	Text	Дорожка генов в IGV, положение TSS относительно пиков
BAM	Выравнивания ридов на геном — бинарная сжатая (BGZF) версия SAM: для каждого рида хромосома, позиция, MAPQ, CIGAR, SAM-флаги (пара, ориентация, дубликат), позиция мата, длина фрагмента, последовательность и качество	Binary	Исходные данные ChIP и Input: flagstat, bamCoverage, MACS3, FRiP
BAI	Индекс отсортированного по координатам BAM: какие сжатые блоки покрывают какой участок генома	Binary	Быстрый доступ к региону (samtools `-L` , deepTools, IGV)
BigWig (.bw)	Непрерывный количественный сигнал вдоль генома: одно число на бин (здесь 10 bp) — CPM-покрытие или log2(ChIP/Input). Индексирован и содержит уровни масштабирования, поэтому браузер читает только видимый участок	Binary	Дорожки ChIP, Input, log2; вход для computeMatrix; IGV
BED	Набор геномных интервалов: `chrom start end` + необязательные name, score, strand. Координаты 0-based, полуоткрытые [start, end)	Text	summits.bed (1-bp точка максимума), TSS/гены, результаты bedtools
narrowPeak	BED6+4 — вызванные пики: интервал, name, score, strand + **signalValue** (fold-enrichment в summit), **−log10 p**, **−log10 q**, **смещение summit** от start	Text	Главный результат MACS3: число пиков, FRiP, сравнение стадий, IGV
MACS3 peaks.xls	Подробная таблица пиков MACS3 (1-based координаты, длина, abs_summit, pileup, −log10 p/q, fold enrichment) + заголовок с командой запуска, размером фрагмента *d*, числом фрагментов ChIP и Input. **Это не Excel**, а текст с табуляцией	Text	Проверка параметров и размера фрагмента; число фрагментов для сводной таблицы
TSV	Произвольная таблица с разделителем «табуляция»	Text	frip.tsv, summary, pairwise, jaccard_matrix, stage_specific
deepTools matrix.gz	Матрица *пики × бины*: для каждого summit — значения каждого BigWig в 200 бинах по 20 bp в окне ±2 kb; первая строка — JSON-заголовок с параметрами и метками образцов	Text, gzip	Вход для plotHeatmap и plotProfile
PDF / PNG	Векторное / растровое изображение	Binary	Heatmap, профили, скриншоты IGV, этот отчёт

BAM → BIGWIG → NARROWPEAK

Это три уровня абстракции одних и тех же данных. **BAM** — дискретные события: десятки миллионов отдельных выровненных фрагментов. **BigWig** — непрерывный сигнал: `bamCoverage` считает, сколько ридов перекрывает каждый бин, и нормирует на размер библиотеки (CPM); отдельные риды теряются, остаётся количественная кривая, которую можно сравнивать между образцами и делить ChIP на Input. **narrowPeak** — дискретные обогащённые регионы: MACS3 проверяет в каждой позиции гипотезу «ChIP-сигнал объясняется локальным фоном $K \sim \text{Poisson}(\lambda_{local})$», поправляет p-value по Бенджамини–Хохбергу и склеивает значимые позиции в интервалы. Итого: **alignments → continuous signal → discrete enriched regions**.

4 Методы

Расчёты выполнены на кластере `calc.cod.phystech.edu` через очередь Slurm (4 CPU, 8 GB), окружение `seminar1-chipseq`: samtools 1.24, deepTools 3.5.6, MACS3 3.0.4, bedtools. Все три стадии обработаны **одним и тем же скриптом** `run_stage.sh`, поэтому параметры гарантированно одинаковы. Полные команды — в Приложении.

1. **QC выравниваний:** `samtools flagstat`; число выравниваний ChIP и Input — `samtools view -c`.
2. **Нормированный сигнал:** `bamCoverage --normalizeUsing CPM --binSize 10` для ChIP и Input.
3. **Обогащение:** `bigwigCompare --operation log2 --pseudocount 1 --binSize 10`, т.е. S(x) = $\log_2[(\text{ChIP}(x)+1)/(\text{Input}(x)+1)]$; S > 0 — ChIP выше Input. Псевдосчёт 1 при малых CPM сильно «сжимает» отношение, поэтому абсолютная высота log2-дорожек на стадиях с низким CPM (75ep, 1–2ss) занижена.
4. **Peak calling:** `macs3 callpeak -f BAMPE -g 1360000000 -q 0.01`, контроль — Input. BAMPE берёт размер фрагмента из реальных пар (d = 207 / 210 / 205 bp для 75ep / 1–2ss / 14ss); $\lambda_{local} = \max(\lambda_{genome}, \lambda_{d}, \lambda_{1kb}, \lambda_{10kb})$; порог BH-FDR 1%. Настоящий q-value: $q = 10^{-\text{col9}}$.
5. **FRiP** = (выравнивания ChIP внутри пиков) / (все выравнивания ChIP): `samtools view -c -L peaks.narrowPeak` / `samtools view -c` — тем же способом, что и в примере 5–6ss.
6. **Профили:** `computeMatrix reference-point --referencePoint center` по summits, окно ±2 kb, бин 20 bp → `plotHeatmap`, `plotProfile`.
7. **Сравнение стадий:** для каждой из 6 пар — `bedtools intersect -u` (пики A, перекрывающие B хотя бы на 1 bp), `-v` (пики A без перекрытия с B) и `bedtools jaccard` на отсортированных и слитых интервалах: $J = |A \cap B|_{bp} / |A \cup B|_{bp}$. Стадийно-специфичный пик — без перекрытия ни с одной из трёх других стадий.
8. **IGV:** IGV-Web, геном GRCz11/danRer11 с аннотацией RefSeq. Для загрузки из BigWig вырезаны окна ±30 kb вокруг выбранных локусов, хромосомы переименованы из RefSeq в UCSC (длины совпадают), скрипт `make_igv_bundle.py`.

5 Результаты по стадиям

5.1 QC выравниваний

Стадия	ChIP, выравнивания	ChIP, фрагменты	Input, выравнивания	Input, фрагменты	Input / ChIP	mapped / properly paired
75ep	23 863 894	11 931 947	39 931 858	19 965 929	1.67	100% / 100%
1–2ss	12 816 614	6 408 307	33 460 348	16 730 174	2.61	100% / 100%
5–6ss	18 853 396	9 426 698	≈57 051 062*	28 525 531	3.03	нет данных
14ss	41 553 880	20 776 940	27 794 668	13 897 334	0.67	100% / 100%

Табл. 2. Фрагменты — из заголовка MACS3 peaks.xls. *Для 5–6ss BAM недоступен; число выравниваний Input оценено как 2 × число фрагментов.

Во всех BAM 100% ридов картированы и составляют правильные пары, нет вторичных и дополнительных выравниваний, дубликаты не помечены (redundant rate MACS3 = 0). Значит, файлы уже прошли фильтрацию, и flagstat описывает готовый набор, а не качество исходного секвенирования. Главное техническое различие между стадиями — **глубина**: ChIP 1–2ss в 3.2 раза мельче, чем 14ss, а соотношение ChIP/Input на 14ss обратное по сравнению с остальными стадиями.

5.2 Peak calling: самые значимые пики

Стадия	Пиков	Самый значимый пик (col 9)	signalValue	−log10 p	−log10 q	q-value
75ep	36	NC_007113.7 (chr2):33 276 014–33 276 551	21.70	109.26	100.05	$8.9{\cdot}10^{-101}$
1–2ss	40	NC_007113.7 (chr2):33 276 062–33 276 596	21.23	65.27	56.18	$6.6{\cdot}10^{-57}$
5–6ss	839	NC_007117.7 (chr6):32 206 483–32 207 024	21.10	172.91	163.70	$2.0{\cdot}10^{-164}$
14ss	170	NC_007126.7 (chr15):35 583 506–35 583 991	25.00	330.35	321.45	$3.5{\cdot}10^{-322}$

Табл. 3. Сортировка по 9-й колонке narrowPeak (−log10 q): `sort -k9,9gr`. Настоящий q-value = $10^{-\text{col9}}$.

На обеих ранних стадиях самый значимый пик — **один и тот же локус** на chr2 (~33.276 Mb), с почти одинаковым fold-enrichment (~21). При этом −log10 q различается почти вдвое (100 против 56): у 1–2ss почти вдвое меньше ChIP-ридов. Самый «значимый» пик во всём наборе — у 14ss ($q \approx 10^{-322}$, предел точности double), но это прежде всего следствие самой большой глубины ChIP, а не самого сильного связывания. **q-value отвечает на вопрос «насколько мы уверены», а не «насколько сильно связан фактор».**

> **МОЖНО ЛИ СЧИТАТЬ 36 / 40 / 839 / 170 ЧИСЛОМ САЙТОВ СВЯЗЫВАНИЯ FOXD3?**
>
> Нет. Это число интервалов, прошедших порог q < 0.01 при данной глубине и данном Input. Слабые, но настоящие сайты не проходят порог (особенно при малой глубине); два близких сайта могут слиться в один интервал; часть пиков — артефакты картирования (см. 6.4); наконец, ChIP сделан из целого эмбриона, и связывание в малой популяции клеток «разбавлено».

5.3 Heatmap и средние профили вокруг summit

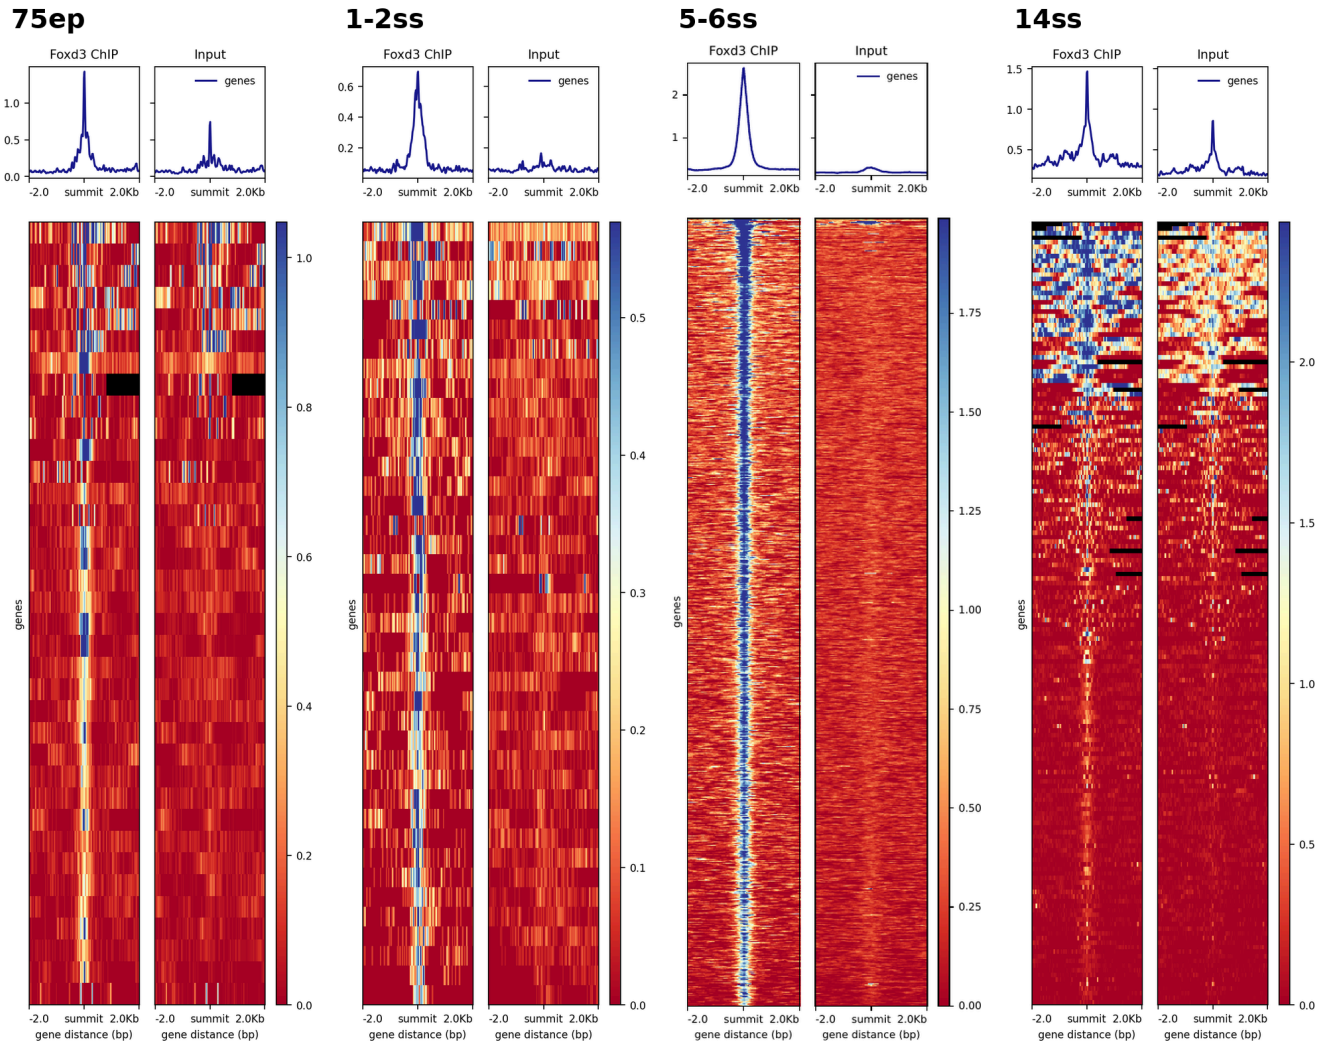


Рис. 1. plotHeatmap для четырёх стадий (слева ChIP CPM, справа Input CPM; окно ±2 kb вокруг summit, пики отсортированы по среднему сигналу). Цветовые шкалы у панелей разные. Чёрные полосы — окно выходит за конец короткого скаффолда (нет данных). Подписи «genes / gene distance» — стандартные подписи deepTools; строки здесь — пики.

- **75ep:** центральная полоса ChIP видна в большинстве строк, но в верхних строках Input тоже высокий и полосатый — часть пиков лежит в регионах с повышенным фоном. На среднем профиле Input в центре поднимается до ~0.55 CPM против ~1.1 CPM у ChIP.
- **1–2ss:** абсолютный сигнал ChIP самый низкий (≈0.6 CPM в центре — следствие малой глубины), но Input в центре почти плоский: контраст с фоном чистый.
- **5–6ss:** самая однородная картина — узкая полоса во всех 839 строках, Input ровный. Это стадия с самым качественным и самым многочисленным набором пиков.
- **14ss:** верхняя треть heatmap — «шумные» строки с высоким сигналом и в ChIP, и в Input; это в основном пики на скаффолдах NW_ (см. 6.4). Ниже — слабые, но настоящие пики с узкой центральной полосой.

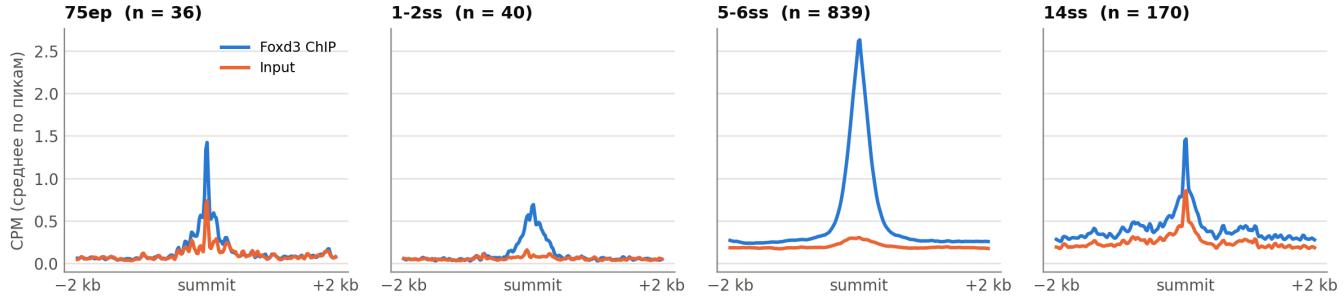


Рис. 2. Средние профили ChIP и Input вокруг summit с **общей осью Y** (CPM), построены по matrix.gz всех четырёх стадий. В отличие от стандартных plotProfile, здесь высоту можно сравнивать напрямую.

Отношение ChIP / Input в центре профиля: 75ep — 2.1, 1–2ss — 7.0, 5–6ss — 8.3, 14ss — 1.7. У 75ep и 14ss обогащение «съедается» поднятым в центре Input: среди их пиков заметная доля лежит в регионах с высоким фоном.

6 Сравнение четырёх стадий

6.1 Сводная таблица

Stage	ChIP alignments	Input alignments	Peaks	FRiP	FRiP, %	max −log10(q)	медиана FE	ChIP/Input в summit
75ep	23 863 894	39 931 858	36	0.000172	0.017	100.05	5.64	2.1
1–2ss	12 816 614	33 460 348	40	0.000140	0.014	56.18	6.00	7.0
5–6ss	18 853 396	≈57 051 062	839	0.002360	0.236	163.70	5.52	8.3
14ss	41 553 880	27 794 668	170	0.001621	0.162	321.45	3.29	1.7

Табл. 4. Сводные метрики. FRiP: 4 101 / 1 799 / 44 485 / 67 346 выравниваний в пиках. Медиана FE — медиана signalValue по всем пикам стадии.

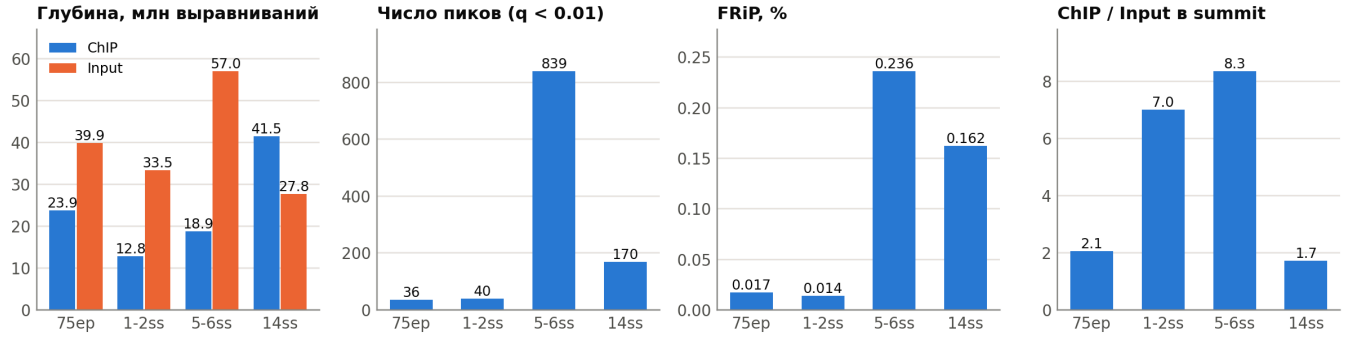


Рис. 3. Глубина библиотек, число пиков, FRiP и отношение ChIP/Input в summit. У каждой панели своя шкала.

- **Больше всего пиков — на 5–6ss (839)**, и это нельзя объяснить глубиной: ChIP 5–6ss мельче, чем 75ep и 14ss, а пиков в 5–20 раз больше. У 5–6ss же максимальный FRiP (0.24%) и самый чистый профиль.
- **ChIP enrichment наиболее выражен на 5–6ss** (отношение ChIP/Input 8.3, чистая heatmap). По медианному fold-enrichment ранние стадии не уступают (5.6–6.0), но у них всего по 36–40 пиков. 14ss — самая глубокая библиотека с самыми «значимыми» q-value, но с самым слабым обогащением (медиана FE 3.3, ChIP/Input 1.7).
- FRiP у всех стадий очень низкий (0.01–0.24%) — типично для bioChIP фактора транскрипции из целых эмбрионов, где Foxd3$^+$ клеток мало. Кроме того, FRiP растёт просто оттого, что пиков больше и они покрывают больше генома, поэтому сравнивать его между стадиями с 36 и 839 пиками надо осторожно.

МОЖНО ЛИ ОБЪЯСНИТЬ РАЗНИЦУ В ЧИСЛЕ ПИКОВ ТОЛЬКО БИОЛОГИЕЙ? — НЕТ

Технические факторы, которые меняют число вызванных пиков независимо от биологии:

- **глубина ChIP** — чем меньше ридов, тем меньше сайтов проходит q < 0.01 (1–2ss: 12.8 M против 41.6 M у 14ss);
- **глубина и качество Input** — от него зависит λ_{local}; кроме того, MACS3 масштабирует большую библиотеку к меньшей;
- **эффективность IP (signal-to-noise)** — различается между библиотеками и видна по FRiP и профилям;
- **доля Foxd3$^+$ клеток в эмбрионе** — на ранних стадиях их мало, сигнал разбавлен (это наполовину биология, наполовину свойство дизайна «целый эмбрион»);
- **артефакты картирования** — повторы и неразмещённые скаффолды (31% пиков 14ss, см. 6.4); фильтрация митохондриальных ридов (пример `mitochondrial_artifact`);
- **обработка 5–6ss выполнена отдельно** (преподавателем), и мы не можем проверить, что параметры идентичны; **нет биологических повторов**, поэтому нельзя оценить воспроизводимость.

6.2 Попарные сравнения наборов пиков

A	B	пиков A	пиков B	A ∩ B (пики A)	B ∩ A (пики B)	только A	только B	Jaccard
75ep	1–2ss	36	40	12 (33%)	12 (30%)	24	28	**0.174**
75ep	5–6ss	36	839	22 (61%)	22 (2.6%)	14	817	0.023
75ep	14ss	36	170	18 (50%)	18 (11%)	18	152	0.075
1–2ss	5–6ss	40	839	30 (75%)	30 (3.6%)	10	809	0.028
1–2ss	14ss	40	170	12 (30%)	12 (7.1%)	28	158	0.043
5–6ss	14ss	839	170	40 (4.8%)	40 (24%)	799	130	0.037

Табл. 5. Все 6 попарных сравнений. «Только A» — пики A без перекрытия с B (специфичны относительно этой пары, но не обязательно относительно всех стадий).

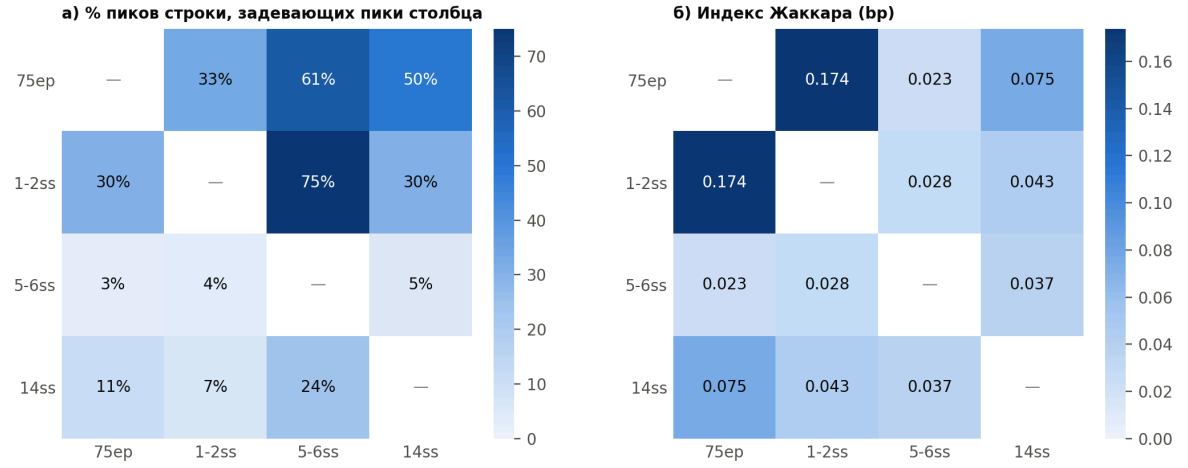


Рис. 4. (а) Направленная доля перекрытия: насколько набор-строка вложен в набор-столбец. (б) Индекс Жаккара — симметричная мера по нуклеотидам; при сильно разных размерах наборов он всегда мал.

6.3 Стадийно-специфичные и общие пики

Стадия	Пиков	Специфичны для стадии	Есть хотя бы на одной другой
75ep	36	6 (17%)	30
1–2ss	40	7 (18%)	33
5–6ss	839	773 (92%)	66
14ss	170	119 (70%)	51

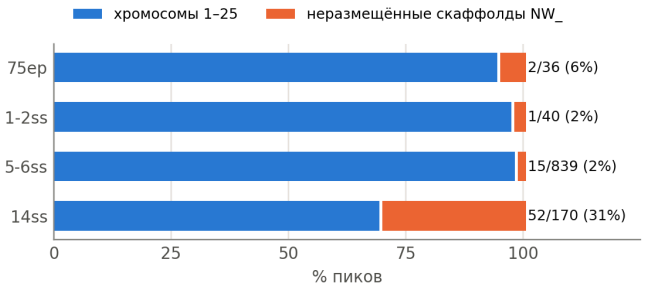
Табл. 6. Стадийно-специфичный пик не перекрывается ни с одним пиком трёх других стадий. На всех четырёх стадиях одновременно присутствуют **6 локусов** (chr6:32.206 Mb, chr2:33.276 Mb, chr16:7.515 Mb, chr20:9.428 Mb, chr18:44.276 Mb, chr4:24.986 Mb).

Какие стадии наиболее похожи? По индексу Жаккара — **75ep и 1–2ss** (0.174): у них общий главный пик и сходный небольшой набор сильных локусов. По направленной доле ранние наборы почти вложены в 5–6ss: **61% пиков 75ep и 75% пиков 1–2ss** есть и на 5–6ss. Жаккар для этих пар мал только потому, что набор 5–6ss в 20 раз больше.

Какие различаются сильнее всего? 5–6ss и 14ss: лишь 40 из 839 пиков 5–6ss (4.8%) сохраняются на 14ss, и только 24% пиков 14ss совпадают с 5–6ss. Также слабо похожи 1–2ss и 14ss (Жаккар 0.043).

Есть ли признаки сильной перестройки? Да, но с оговорками. (1) Между 1–2ss и 5–6ss набор расширяется в ~20 раз, при этом ранние сайты в основном сохраняются: к стадии спецификации к «ядру» ранних сайтов добавляются сотни новых. (2) Между 5–6ss и 14ss большая часть сайтов 5–6ss перестаёт детектироваться, а у 14ss 70% пиков новые. Однако значительная часть «новых» пиков 14ss — артефакты скаффолдов (6.4), так что реальная доля новых сайтов на 14ss меньше.

6.4 Техническая особенность 14ss: пики на неразмещённых скаффолдах



52 из 170 пиков 14ss (31%) лежат на неразмещённых скаффолдах `NW_…` (20 — на одном `NW_003336678.1`). У остальных стадий — 1–6%. У этих пиков низкий fold-enrichment (~3), но огромная значимость (−log10 q до 148), и Input в них тоже высокий (средний CPM в центре 1.55 против 0.39 у пиков на хромосомах). Все топовые «14ss-специфичные» пики — именно такие.

Это типичная картина для повторов и плохо собранных участков генома: риды многократно картируются, покрытие завышено и в ChIP, и в Input, а при большой глубине даже малое превышение даёт значимый q. **Эти пики следует считать техническими** и исключать перед биологической интерпретацией (например, фильтром по хромосомам или blacklist).

Рис. 5. Доля пиков на хромосомах 1–25 и на неразмещённых скаффолдах NW_.

> **ПОЧЕМУ ОТСУТСТВИЕ ПИКА НА ДРУГОЙ СТАДИИ НЕ ДОКАЗЫВАЕТ ОТСУТСТВИЕ СВЯЗЫВАНИЯ**
>
> Вызов пика — бинарное решение по порогу. Сайт может быть связан, но (1) сигнал немного ниже порога q < 0.01, особенно в мелкой библиотеке (1–2ss) — это ложноотрицательный результат; (2) связывание есть в малой субпопуляции клеток и теряется в целом эмбрионе; (3) пик смещён или разбит, и интервалы формально не перекрываются. Поэтому сравнение по наборам пиков надо дополнять количественным сигналом в этом месте на всех стадиях — это и показывают скриншоты IGV (рис. 6–8): там, где пика нет, часто виден слабый подпороговый сигнал.

7 Визуализация в IGV

Дорожки сверху вниз: ChIP CPM и Input CPM стадии 5–6ss; log2(ChIP/Input) для 75ep, 1–2ss, 5–6ss и 14ss; пики (narrowPeak) четырёх стадий; последовательность и гены RefSeq. **Шкалы log2-дорожек автоматические и различаются** — числа у левого края дорожек (максимумы приведены в подписях).

7.1 Скриншот 1 — сильный пик 5–6ss: chr3 (NC_007114.7):14 912 700–14 916 300

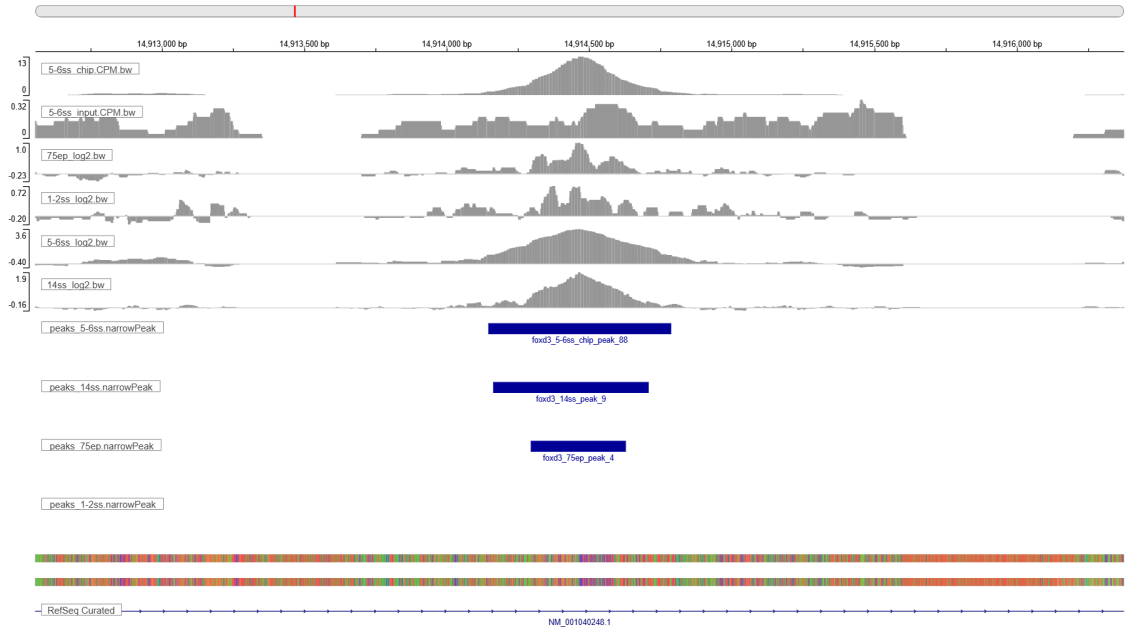


Рис. 6. Пик `foxd3_5-6ss_chip_peak_88`, chr3:14 914 145–14 914 787 — самый высокий fold-enrichment на 5–6ss (signalValue 31.0, −log10 q 135.7). Максимум log2(ChIP/Input): 75ep 1.03 · 1–2ss 0.72 · **5–6ss 3.57** · 14ss 1.88. Пик лежит внутри гена NM_001040248.1 (интрон).

ChIP 5–6ss образует чёткий пик высотой ~12.5 CPM, тогда как Input на том же месте остаётся на уровне фона (~0.3 CPM): обогащение не объясняется особенностями хроматина или картируемостью. Пик вызван также на 75ep и 14ss (на 14ss — второй по значимости во всём наборе, FE 34.7), а на 1–2ss сигнал есть, но ниже порога — хороший пример ложноотрицательного результата при малой глубине.

7.2 Скриншот 2 — локус, общий для всех стадий: chr2 (NC_007113.7):33 270 999–33 281 609

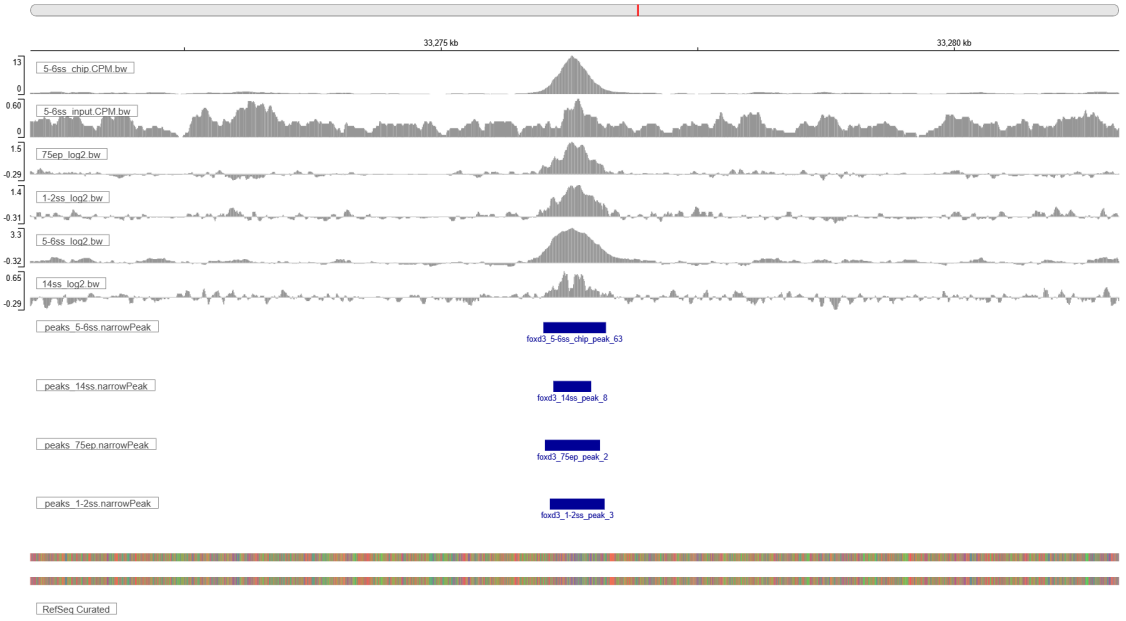


Рис. 7. Пик на chr2:~33 276 000 вызван на всех четырёх стадиях. Максимум log2(ChIP/Input): 75ep 1.54 · 1–2ss 1.44 · **5–6ss 3.27** · 14ss 0.67. FE: 21.7 / 21.2 / 20.3 / 5.5. Генов RefSeq в окне ±5 kb нет — вероятно, дистальный регуляторный элемент.

Одинаков ли enrichment? Нет. Для 75ep и 1–2ss это главный пик всего набора; на 5–6ss сигнал максимальный (ChIP ~12.9 CPM); на 14ss пик ещё вызывается, но log2 и FE падают в 3–4 раза. Локус присутствует на всех стадиях, но сила связывания меняется — бинарное «пик есть / пика нет» эту динамику не показывает.

7.3 Скриншот 3 — стадийно-смещённый локус: chr1 (NC_007112.7):254 734–265 218

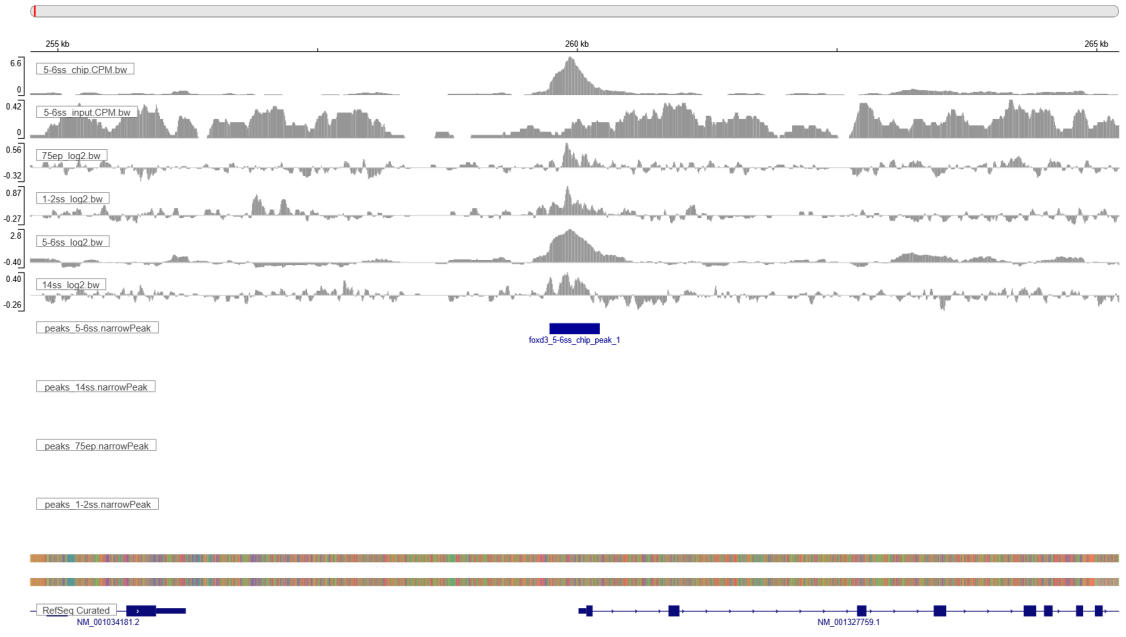


Рис. 8. Пик `foxd3_5-6ss_chip_peak_1`, chr1:259 734–260 218 (signalValue 21.0, –log10 q 63.0) вызван **только на 5–6ss**. Максимум log2(ChIP/Input): 75ep 0.56 · 1–2ss 0.87 · **5–6ss 2.78** · 14ss 0.40. Пик перекрывает 5′-конец (TSS) гена NM_001327759.1.

На 5–6ss — выраженный пик в промоторной области гена; на остальных стадиях в том же месте видны лишь небольшие подпороговые «бугорки» log2. Такой локус корректнее называть **stage-biased** (с сильным смещением к 5–6ss), а не строго stage-specific: слабое связывание на других стадиях не исключено.

8 Биологическая интерпретация

1. **Постоянен ли ландшафт связывания Foxd3?** Нет. Он меняется в два этапа: от 75ep/1–2ss к 5–6ss набор сайтов резко расширяется (36–40 → 839 пиков, FRiP в 14–17 раз выше), причём 61–75% ранних пиков сохраняются; от 5–6ss к 14ss большинство сайтов 5–6ss (95%) перестаёт детектироваться.
2. **Самый выраженный ChIP-сигнал — на 5–6ss** (стадия спецификации): максимум пиков, FRiP, отношения ChIP/Input и самый однородный профиль. Это согласуется с тем, что к 5–6ss Foxd3 экспрессируется в большом числе клеток премиграторного нервного гребня.
3. **Стабильные участки** — небольшое ядро из 6 локусов, найденных на всех стадиях (например, chr2:33.276 Mb и chr6:32.206 Mb), и 30–33 ранних пика, сохраняющихся хотя бы на одной поздней стадии. Даже в стабильных локусах сила связывания меняется (рис. 7).
4. **Появляющиеся и исчезающие участки** — сотни сайтов 5–6ss, которых нет на ранних стадиях (например, промотор на chr1:260 kb, рис. 8), и которые в основном не детектируются на 14ss. «Новые» пики 14ss частично технические (31% — на скаффолдах NW_), частично могут отражать новые мишени на стадии миграции.

Такая динамика совпадает с моделью авторов статьи: на ранних стадиях Foxd3 связывает ограниченный набор элементов как **pioneer-фактор**, открывая регуляторные участки программы нервного гребня; к стадии спецификации число мишеней растёт; позднее функция смещается в сторону **репрессора**, и репертуар связывания меняется.

> **ПОЧЕМУ ПО ОДНОМУ CHIP-SEQ НЕЛЬЗЯ СКАЗАТЬ, АКТИВИРУЕТ FOXD3 БЛИЖАЙШИЙ ГЕН ИЛИ РЕПРЕССИРУЕТ**
>
> - **Binding ≠ regulation:** пик показывает физическое присутствие белка (к тому же усреднённое по всем клеткам эмбриона), но не его влияние на транскрипцию.
> - **Peak ≠ target gene:** дистальный энхансер может регулировать ген в десятках–сотнях kb; ближайший TSS — только гипотеза (пик на chr2 вообще не имеет генов рядом).
> - ChIP-seq Foxd3 не показывает, открыт ли хроматин и активен ли энхансер, и не показывает изменения экспрессии.
> - Foxd3 по данным статьи бывает и активатором, и репрессором, поэтому направление эффекта из факта связывания не выводится.

Какие данные статьи нужны для проверки функционального эффекта. Авторы сравнивают отсортированные FACS клетки foxd3-control (Citrine$^+$/mCherry$^-$) и foxd3-mutant (Citrine$^+$/mCherry$^+$):

- **ATAC-seq** — меняется ли доступность хроматина в сайтах связывания Foxd3 при его потере (pioneer-функция: сайт закрывается в мутанте), плюс позиционирование нуклеосом;
- **H3K27ac ChIP-seq** — меняется ли активность энхансера (активатор: H3K27ac падает в мутанте; репрессор: растёт);
- **RNA-seq** (bulk и Smart-seq2) — меняется ли экспрессия генов рядом с Foxd3-связанными элементами.

Только совпадение цепочки «Foxd3 связан → в мутанте меняется доступность и/или H3K27ac → меняется экспрессия гена» позволяет говорить о прямой регуляции.

9 Вывод

Как меняется ландшафт связывания Foxd3 от гаструляции к миграции нервного гребня? На гаструляции и при индукции (75ep, 1–2ss) детектируется небольшой набор сильных сайтов, частично общий для обеих стадий. К стадии спецификации (5–6ss) связывание резко расширяется — сотни новых пиков с самым чистым обогащением, — причём большинство ранних сайтов сохраняется. К стадии миграции (14ss) репертуар снова

перестраивается: большинство сайтов 5–6ss больше не детектируется, а даже сохранившиеся общие локусы связываются слабее.

Что можно уверенно считать биологическим: (1) максимум связывания на 5–6ss — его нельзя объяснить глубиной (ChIP 5–6ss мельче 75ep и 14ss) и он подтверждается FRiP, профилем и отношением ChIP/Input; (2) вложенность ранних пиков в набор 5–6ss (61–75%); (3) существование стабильного ядра локусов с меняющейся силой связывания, видимое напрямую в IGV.

Что нельзя отделить от качества ChIP-seq: (1) точное число пиков на каждой стадии и малое число пиков на 75ep/1–2ss — глубина ChIP различается в 3.2 раза, а слабые сайты теряются под порогом; (2) масштаб «исчезновения» сайтов 5–6ss на 14ss и «появления» новых — 14ss имеет самое слабое обогащение, а 31% её пиков — артефакты скаффолдов; кроме того, 5–6ss обработана отдельно; (3) любые различия, основанные на отсутствии пика. Для строгого ответа нужны биологические повторы, выравнивание глубины (downsampling), единый консенсусный набор регионов с количественным сравнением сигнала, фильтрация по blacklist/скаффолдам и контроль BirA-only.

П Приложение: команды

Скрипты целиком — в репозитории (`scripts/`). Все шаги для одной стадии (`STAGE` = 75ep, 1-2ss, 14ss), запуск: `sbatch scripts/job.sbatch` → `run_all.sh` → `run_stage.sh` для каждой стадии → `compare_stages.sh` .

```
CHIP=data/$STAGE/foxd3_${STAGE}_chip.nuclear.bam
INPUT=data/$STAGE/foxd3_${STAGE}_input.nuclear.bam
# 1. QC
samtools flagstat -@ 4 $CHIP  > results/qc/foxd3_${STAGE}_chip.flagstat.txt
samtools flagstat -@ 4 $INPUT > results/qc/foxd3_${STAGE}_input.flagstat.txt
# 2. CPM BigWig
bamCoverage -b $CHIP  -o results/signal/foxd3_${STAGE}_chip.CPM.bw  --normalizeUsing CPM --binSize
10 --numberOfProcessors 4
bamCoverage -b $INPUT -o results/signal/foxd3_${STAGE}_input.CPM.bw --normalizeUsing CPM --binSize
10 --numberOfProcessors 4
# 3. log2(ChIP/Input)
bigwigCompare -b1 results/signal/foxd3_${STAGE}_chip.CPM.bw -b2
results/signal/foxd3_${STAGE}_input.CPM.bw \
  --operation log2 --pseudocount 1 --binSize 10 -o results/signal/foxd3_${STAGE}.log2_IP_Input.bw
# 4. Peak calling
macs3 callpeak -t $CHIP -c $INPUT -f BAMPE -g 1360000000 -n foxd3_${STAGE} -q 0.01 --outdir
results/peaks
wc -l results/peaks/foxd3_${STAGE}_peaks.narrowPeak
# 5. Самый значимый пик и настоящий q-value
sort -k9,9gr results/peaks/foxd3_${STAGE}_peaks.narrowPeak | awk 'NR<=10'
awk '{x=$9; e=int(x); if(e<x)e++; printf "%.3fe-%d\n", 10^(e-x), e}'   # q = 10^(-col9)
# 6. FRiP
TOTAL=$(samtools view -@ 4 -c $CHIP)
INPEAKS=$(samtools view -@ 4 -c -L results/peaks/foxd3_${STAGE}_peaks.narrowPeak $CHIP)
awk -v a=$INPEAKS -v b=$TOTAL 'BEGIN{printf "%.6f\n", a/b}'
# 7. Heatmap и профиль вокруг summit
computeMatrix reference-point --referencePoint center -R results/peaks/foxd3_${STAGE}_summits.bed \
  -S results/signal/foxd3_${STAGE}_chip.CPM.bw results/signal/foxd3_${STAGE}_input.CPM.bw \
  -b 2000 -a 2000 --binSize 20 -p 4 -o results/figures/foxd3_${STAGE}.matrix.gz
plotHeatmap -m results/figures/foxd3_${STAGE}.matrix.gz -out
results/figures/foxd3_${STAGE}.heatmap.pdf \
  --samplesLabel "Foxd3 ChIP" "Input" --refPointLabel summit
plotProfile -m results/figures/foxd3_${STAGE}.matrix.gz -out
results/figures/foxd3_${STAGE}.profile.pdf \
  --samplesLabel "Foxd3 ChIP" "Input" --refPointLabel summit --perGroup
```

Сравнение стадий (для каждой из 6 пар A, B; 5–6ss — `teacher/5-6ss/peaks/foxd3_5-6ss_chip_peaks.narrowPeak`):

```
sort -k1,1 -k2,2n A.narrowPeak > A.sorted ;  cut -f1-3 A.sorted | bedtools merge > A.merged.bed
bedtools intersect -a A.sorted -b B.sorted -u | wc -l      # пики A, перекрывающие B
bedtools intersect -a A.sorted -b B.sorted -v | wc -l      # пики A без перекрытия с B
bedtools jaccard   -a A.merged.bed -b B.merged.bed         # индекс Жаккара (колонка 3)
# специфичные для стадии S: нет перекрытия ни с одной другой стадией
cat OTHER1.merged.bed OTHER2.merged.bed OTHER3.merged.bed | sort -k1,1 -k2,2n | bedtools merge >
others.bed
bedtools intersect -a S.sorted -b others.bed -v | wc -l
# пики на неразмещённых скаффолдах
grep -c '^NW_' results/peaks/foxd3_${STAGE}_peaks.narrowPeak
```

Запуск на кластере (`scripts/job.sbatch`):

```
#SBATCH -p E5-2630-TITAN_X
#SBATCH -J foxd3_chip -c 4 --mem=8G -t 10:00:00 -o logs/slurm_%j.log
cd ~/chipseq_seminar && bash scripts/run_all.sh
```